

Dossier technique

Scoring de confiance des composants IA

Système IDeXtend

Conformité AI Act — Annexe III §6
Système à haut risque — Application de la loi

Auteur	Leveque Rayan
Date	11 May 2026
Version	0.1 — Brouillon
Branche git	feature/evaluation-modele

Résumé exécutif

IDeXtend est un système RAG (*Retrieval-Augmented Generation*) d'aide à l'enquête judiciaire déployé à la CFIA Gendarmerie nationale. Classifié **système à haut risque** au titre de l'Annexe III §6 de l'AI Act (Règlement UE 2024/1689), il est soumis à des exigences strictes de transparence, de robustesse et de surveillance humaine (Art. 9, 13, 15). Ce dossier documente scientifiquement le **système de scoring de confiance** de chaque composant du pipeline.

État d'implémentation au 11 mai 2026

Composant	Modèle	compute_confidence()	Validé
OCR	QwenVL 2.5-7B	A implémenter	Non
ASR (Whisper)	whisper-large-v3	A implémenter	Non
Embeddings	BAAI/bge-m3	A implémenter	Non
Reranker	BAAI/bge-reranker-v2-m3	Implémenté	Non
LLM (Qwen3)	Qwen3-4B	A définir	Non
Traduction	NLLB-600M	Implémenté	Non
Détection langue	FastText LID	Implémenté	Non

Fiche composant — OCR (Reconnaissance Optique de Caractères)

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

Composant du pipeline IDeXtend.

2.1 1. Identification

Champ	Valeur
Nom du composant	OCR — Reconnaissance Optique de Caractères
Version / modèle retenu	Mode actif : QwenVL 2.5-7B (via llama.cpp ou vLLM) · Mode legacy : EasyOCR 1.7 + Tesseract 5.x
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon
Place dans le pipeline IDeXtend	DataPipelines/OCR.py → OcrTask.execute() — déclenché par pipelines_definition.json, consomme VLModel (mode actif) ou OcrModel (mode legacy)

2.2 2. Définition de la fonctionnalité

Rôle dans le système.

Le composant OCR convertit les images en texte exploitable. Il est déclenché sur chaque nœud image attaché à un document ingéré qui porte le flag `OCR_FLAG = True`. Le texte produit est ensuite découpé en chunks, embeddings générés, et potentiellement traduit vers le français si la langue détectée diffère de `fra_Latn`. L'OCR conditionne directement la qualité de toute l'analyse aval : un OCR défaillant produit des chunks bruités, des embeddings peu pertinents, et des réponses LLM erronées.

Entrée.

- Format : image binaire (JPEG, PNG, BMP, TIFF, WebP) ; chemin fichier passé à `infer()`
- Source : nœuds Image dans la base ArcadeDB, liés à un Document parent
- Volume typique : 1–50 images par document ; résolution variable (scans police : 150–300 dpi)
- Filtres appliqués avant OCR : image > 100×100 px, ratio max/min < 10 (rejet des bandes fines)

Sortie.

- Format : `str` — texte brut multi-lignes, reconstitué par ordre de lecture (haut→bas, gauche→droite)
- Consommateur en aval : `chunk_creation()` → `EmbeddingsModel` → `TranslationModel` (si besoin) → `LlmModelIngestion`

Criticité AI Act.

Annexe III §6 — application de la loi. Une erreur OCR peut :

- 1.Manquer un élément d'identification (nom, date, numéro de véhicule) sur une pièce scannée
- 2.Introduire des termes inexacts dans la base vectorielle, générant de faux positifs/négatifs lors des recherches
- 3.Conduire un enquêteur à écarter une piste pertinente ou à retenir une piste erronée

Un score de confiance bas doit déclencher une relecture humaine obligatoire avant tout usage opérationnel du texte.

2.3 3. Modèles évalués

Modèle	Version	Source	Inclus dans le benchmark	Retenu
EasyOCR + Tesseract	EasyOCR 1.7, Tesseract 5.x	Open-source	oui (mode legacy, baseline)	non (sauf fallback)
QwenVL 2.5-7B	7B, Q8 quantization	Alibaba/HuggingFace	oui (actif)	oui
Marker	1.x	VikParuchuri/marker	à benchmarker	non
Docling	2.x	IBM/docling	à benchmarker	non
InternVL 3.5-7B	7B	OpenGVLab	à benchmarker	non

Critères de présélection.

- Licence Apache 2.0 ou MIT compatible déploiement interne (pas de données hors périmètre)
- Support multilingue FR/EN/AR (exigence Gendarmerie)
- Déployable on-premise sur GPU ≤ 24 Go VRAM
- Capacité à traiter documents dégradés (scans police, photocopies, documents manuscrits partiels)

Justification du mode QwenVL retenu.

QwenVL 2.5-7B est un VLM (Visual Language Model) qui traite l'image entière en contexte plutôt que région par région comme Tesseract. Il gère nativement : orientation arbitraire, mélange FR/AR/EN, tableaux, formulaires structurés. Le mode legacy EasyOCR + Tesseract reste disponible via `config.ini` : `[OCR] mode = legacy` pour des cas de débogage ou de machines sans GPU.

Points ouverts (benchmark à compléter).

- Marker et Docling sont présents dans le codebase (`DataPipelines/markerworker.py`, `DataPipelines/doclingworker.py`) mais non comparés formellement sur des

documents opérationnels Gendarmerie

- InternVL 3.5-7B est configuré dans `llm_configs/internvl3.5-7b-1user-q8-q8-8k-llamacpp.yaml` mais non évalué

2.4 4. Protocole d'évaluation

Dataset d'évaluation.

- Nom / description : **à créer** — dataset de référence à partir de documents réels anonymisés (PV, formulaires administratifs, photos de scène) + ground-truth OCR annoté manuellement
- Taille recommandée : ≥ 200 images, représentant au moins 5 types de documents différents
- Représentativité : les données de production incluent des scans dégradés, des photos prises au smartphone, des documents manuscrits partiels — le dataset doit en reproduire la distribution
- Annotation : transcription manuelle par 2 annotateurs, accord inter-annotateurs mesuré par Character Agreement Rate $\geq 95\%$
- Disponibilité : interne, accès restreint CFIA

Métriques de performance brute.

Métrique	Description	Outil
CER (Character Error Rate)	$(S + D + I) / N$ — taux d'erreur au niveau caractère	jiwer ou editdistance
WER (Word Error Rate)	Taux d'erreur au niveau mot	jiwer
NED (Normalized Edit Distance)	Distance d'édition normalisée, robuste aux longueurs variables	custom
F1 mot	Précision/Rappel sur les mots détectés (utile pour extraction d'entités)	custom

Résultats du benchmark.

Modèle	CER	WER	Latence moy. (s/image)	VRAM (Go)
EasyOCR + Tesseract (legacy)	à mesurer	à mesurer	~2–5	~10
QwenVL 2.5-7B (actif)	à mesurer	à mesurer	~3–8	~8 (Q8)
Marker	à mesurer	à mesurer	à mesurer	à mesurer
Docling	à mesurer	à mesurer	à mesurer	à mesurer

Justification du modèle retenu.

QwenVL 2.5-7B retenu sur la base de tests qualitatifs informels montrant une meilleure gestion des documents multilingues FR/AR et des documents partiellement dégradés. Validation quantitative (CER/WER sur dataset annoté) à compléter pour le dossier AI Act.

2.5 5. Fonction de scoring de confiance

État actuel : aucune `compute_confidence()` implémentée pour `VLMModel` (mode actif). Le mode legacy (`image/ocr.py`) calcule déjà un `average_confidence` Tesseract interne (lignes 161–163) mais ne l'expose pas via `ConfidenceScore`.

2.5.1 5a. Mode legacy (EasyOCR + Tesseract)

Définition formelle.

Soit $W = \{w_1, \dots, w_n\}$ les mots détectés par Tesseract, et $c_i \in [0, 100]$ la confiance par mot (colonne `conf` de `image_to_data()`). Les valeurs $c_i = -1$ correspondent à des zones non-texte et sont exclues.

$$s_{\text{legacy}}(x, y) = (1 / (|W^+|)) \sum_i : c_i \geq 0 (c_i / 100) \in [0, 1]$$

où $W^+ = \{w_i : c_i \geq 0\}$. La rotation de l'image (logique `has_180_rotated`) retient le texte avec le score moyen le plus élevé.

Plage de valeurs. $s \in [0, 1]$

2.5.2 5b. Mode VLM / QwenVL (actif) — proposition

Le VLM ne produit pas de scores par token accessibles via l'API `llama.cpp/vLLM` actuelle. Deux approches sont proposées, à valider empiriquement :

Option A — Verbalized Confidence (recommandée pour l'audit AI Act)

Modifier le prompt OCR pour demander au modèle d'auto-évaluer sa confiance :

```
Transcris le texte visible dans cette image.  
Termine ta réponse par : CONFIANCE: <entier 0-100>
```

$$s_{\text{VLM-verb}}(x, y) = \text{confiance_verbalisée} / 100 \cdot \delta_{\text{format}}$$

où $\delta_{\text{format}} = 1$ si le format attendu est respecté, 0.5 sinon.

Option B — Self-Consistency (plus robuste scientifiquement)

Lancer K inférences avec température $T > 0$ et mesurer l'accord :

$$s_{\text{SC}}(x) = 1 - (1 / (K(K-1))) \sum_{i \neq j} \text{NED}(y_i, y_j)$$

où NED est la distance d'édition normalisée entre deux transcriptions. Coût : $K \times \text{latence}$.

Option retenue pour implémentation initiale : Option A (verbalized), puis calibration sur dataset annoté pour vérifier la corrélation avec le CER réel.

Plage de valeurs. $s \in [0, 1]$

Interprétation des seuils.

Plage	Interprétation	Action recommandée
$s \geq 0.80$	Haute confiance	Exploitable sans relecture humaine systématique
$0.50 \leq s < 0.80$	Confiance moyenne	Relecture recommandée avant exploitation opérationnelle
$s < 0.50$	Faible confiance	Relecture humaine obligatoire, signal d'alerte sur le dashboard

Note : seuils provisoires — à calibrer sur la corrélation empirique score $\leftrightarrow$ CER (section 7).

2.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] Smith, R. (2007). *An Overview of the Tesseract OCR Engine*. ICDAR. — Fondement du score de confiance Tesseract (conf column) : probabilité de la séquence de caractères la plus probable selon le modèle de langage interne.
- [Ref 2] Bai, J. et al. (2023). *Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond*. arXiv:2308.12966. — Architecture QwenVL et ses capacités de lecture de texte.
- [Ref 3] Wang, P. et al. (2024). *Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution*. arXiv:2409.12191. — QwenVL 2.5 : améliorations OCR multilingue.
- [Ref 4] Xiong, Y. et al. (2023). *Benchmarking Document Understanding: Are Large Language Models Useful?* — Comparaison VLM vs OCR traditionnel sur documents de qualité variable.
- [Ref 5] Kadavath, S. et al. (2022). *Language Models (Mostly) Know What They Know*. arXiv:2207.05221. — Calibration de la confiance verbalisée dans les LLMs.
- [Ref 6] Wang, X. et al. (2022). *Self-Consistency Improves Chain of Thought Reasoning in Language Models*. arXiv:2203.11171. — Principe de self-consistency utilisé dans l'Option B.

Alternatives considérées et rejetées.

- Entropy des log-probs token** : inaccessible via l'API llama.cpp REST actuelle sans modification serveur.
- CER estimé par second modèle** : trop coûteux (double inférence + modèle de référence requis).
- Score de qualité d'image (BRISQUE, NIQE)** : mesure la qualité de l'image, pas la qualité de la transcription — corrélation faible avec le CER en pratique.

Hypothèses sous-jacentes.

1. La confiance verbalisée par le VLM est monotone avec la qualité de transcription (CER) — à valider en section 7.
2. La distribution des documents opérationnels est représentée par le dataset de calibration.
3. Le seuil $\tau = 0.80$ correspond à un CER < 5 % acceptable pour l'exploitation (hypothèse à valider).

2.7 7. Validation empirique du score

Statut : protocole défini, expériences à conduire.

Protocole.

1. Constituer un dataset de 200 images annotées (transcription ground-truth)
2. Lancer l'OCR actif (QwenVL) sur chaque image, collecter le score verbalisé
3. Calculer le CER réel entre transcription produite et ground-truth
4. Binning du score en 5 intervalles [0–0.2), [0.2–0.4), ..., [0.8–1.0]
5. Pour chaque bin : calculer le CER moyen, l'écart-type, et vérifier la monotonie

Corrélation score ↔ qualité.

Test statistique	Valeur	p-value	Interprétation
Spearman ρ (score vs 1-CER)	à mesurer	à mesurer	Attendu : $\rho > 0.5$
Pearson r	à mesurer	à mesurer	
Kendall τ	à mesurer	à mesurer	

Calibration.

- Expected Calibration Error (ECE) : à mesurer
- Maximum Calibration Error (MCE) : à mesurer
- Brier Score : à mesurer
- Reliability diagram : (à joindre après expériences)

Discrimination (binarisation : CER < 10 % = bon).

- AUC-ROC : à mesurer
- AUC-PR : à mesurer
- Seuil optimal et matrice de confusion : à mesurer

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Scan haute résolution (300 dpi, FR)	élevé (≥ 0.80)	à mesurer	
Photo smartphone, bonne lumière	moyen-haut (0.65–0.80)	à mesurer	

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Scan dégradé, photocopie de 3e gen.	bas (< 0.50)	à mesurer	
Texte arabe manuscrit	bas (< 0.50)	à mesurer	
Image sans texte (photo de scène)	bas ou flag	à mesurer	
Texte hors distribution (caractères spéciaux)	bas	à mesurer	

2.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Documents entièrement manuscrits : le VLM peut produire une confiance élevée même avec des erreurs substantielles
- Images contenant du texte dans des langues non supportées (ex. cyrillique, idéogrammes CJK non inclus dans le fine-tuning)
- Documents avec filigranes denses ou tampons superposés au texte

Biais identifiés.

- Performance différentielle : texte imprimé >> texte manuscrit ; latin >> arabe >> autres scripts
- Documents photocopiés en noir et blanc peuvent être pénalisés par le préprocessing couleur
- Biais de longueur : la confiance verbalisée peut être gonflée pour les textes très courts (peu d'incertitude structurelle)

Dérive prévisible.

- Si le modèle QwenVL est mis à jour (changement de version ou de quantization), les seuils doivent être recalibrés
- Recalibration nécessaire si le type de documents ingérés change significativement (ex. ajout de documents en arabe dialectal)

2.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score de confiance bas → relecture humaine obligatoire. Pipeline d'évaluation CER défini.
Art. 10 — Données et gouvernance	Dataset d'évaluation avec données anonymisées, accord inter-annotateurs documenté.
Art. 13 — Transparence	Score affiché sur le dashboard IDeXtend par document. Métadonnées loguées ([CONFIDENCE] model=. . . score=. . .).
Art. 14 — Contrôle humain	Seuil rouge $s < 0.50$ → flag obligatoire relecture. Enquêteur peut override manuellement.

Article / exigence	Comment ce composant y répond
Art. 15 — Exactitude, robustesse	Benchmark CER/WER sur dataset représentatif. Stress tests sur cas dégradés. Monitoring en production.

2.10 10. Monitoring en production

Métriques de suivi.

- Distribution des scores OCR par semaine (histogramme)
- Taux de documents en zone rouge ($S < 0.50$) — alerte si $> 20\%$ sur une fenêtre glissante
- Latence médiane et P95 de l'inférence VLM

Conditions de déclenchement d'une revue.

- Taux de zone rouge passe de $< 15\%$ à $> 25\%$ sur 2 semaines consécutives
- Changement du modèle VLM (version, quantization, prompt)
- Introduction d'un nouveau type de document dans le corpus

Logs et traçabilité.

Format : `[CONFIDENCE] model=DataPipelines.VLMModel.VLMModel score=<float> metadata={...}`

Stocké en base ArcadeDB sur le nœud Document : propriété `confidence_ocr` (JSON).

2.11 11. Annexes

- Code de référence OCR actif : `[DataPipelines/VLMModel.py](../DataPipelines/VLMModel.py)`
- Code de référence OCR legacy : `[image/ocr.py](../image/ocr.py)`,
`[DataPipelines/OcrModel.py](../DataPipelines/OcrModel.py)`
- Tâche pipeline OCR : `[DataPipelines/OCR.py](../DataPipelines/OCR.py)`
- Configuration : `[config.ini](../config.ini)` section `[OCR]`
- Modèle VLM configuré :
`llm_configs/qwenvl2.5-7b-1user-q8-q8-8k-llamacpp.yaml`
- Datasets utilisés : à créer (voir section 4)

Fiche composant — ASR (Reconnaissance Automatique de la Parole) — Whisper

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

3.1 1. Identification

Champ	Valeur
Nom du composant	ASR — Automatic Speech Recognition
Version / modèle retenu	openai/whisper-large-v3
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon
Place dans le pipeline IDeXtend	DataPipelines/WhisperModel.py → WhisperTask — déclenché sur les nœuds audio/vidéo

3.2 2. Définition de la fonctionnalité

Rôle dans le système.

Whisper transcrit les fichiers audio et vidéo en texte. Le texte produit est ensuite traité identiquement aux documents texte (chunking, embeddings, traduction si nécessaire, extraction d'entités). Dans le contexte judiciaire, Whisper peut traiter des enregistrements d'écoutes téléphoniques, d'auditions, ou des vidéos de surveillance avec piste audio.

Entrée.

- Format : fichier audio (WAV, MP3, M4A, FLAC) ou flux audio extrait d'une vidéo
- Source : nœuds Audio dans ArcadeDB, produits par VideoTreatment pour les vidéos
- Volume typique : durée variable, de quelques secondes à plusieurs heures

Sortie.

- Format : `str` — transcription brute multi-segments, jointure des segments chunk
- Note : la HF pipeline retourne `result["text"]` directement (`WhisperModel.infer()` ligne 89)
- Consommateur en aval : `chunk_creation()` → pipeline identique OCR

Criticité AI Act.

Une transcription inexacte peut : (1) attribuer des propos à un locuteur qui ne les a pas tenus, (2) manquer des éléments d'aveu ou de planification criminelle, (3) produire des homophones erronés pour des noms propres critiques (prénoms, adresses, noms d'armes).

3.3 3. Modèles évalués

Modèle	Version	Source	Inclus dans le benchmark	Retenu
Whisper large-v3	large-v3	OpenAI/HuggingFace	oui	oui
Whisper medium	medium	OpenAI	à évaluer	non
Whisper large-v2	large-v2	OpenAI	à évaluer	non
Faster-Whisper (CTranslate2)	CT2 large-v3	SYSTRAN	à évaluer (latence)	non

Critères de présélection.

- WER bas sur FR/EN/AR (langues clés Gendarmerie)
- Déployable on-premise (pas d'API cloud)
- Gestion des accents régionaux, bruits de fond, conversations multi-locuteurs

3.4 4. Protocole d'évaluation

Dataset d'évaluation.

- Public : CommonVoice FR/EN/AR, FLEURS pour le multilinguisme
- Interne : à constituer à partir d'enregistrements anonymisés
- Métriques : WER, CER, BLEU pour transcription multilingue

Métriques de performance brute.

Métrique	Description
WER	Word Error Rate : $(S+D+I)/N$
CER	Character Error Rate
RTF	Real-Time Factor : durée traitement / durée audio

Résultats du benchmark.

Modèle	WER FR	WER EN	WER AR	RTF (GPU)	VRAM
Whisper large-v3	à mesurer	à mesurer	à mesurer	à mesurer	~4.5 Go (batch=8)

Justification du modèle retenu.

whisper-large-v3 retenu sur sa réputation de référence open-source multilinguisme, et sa disponibilité native dans HuggingFace Transformers. Benchmark WER à compléter sur corpus

judiciaire FR.

3.5 5. Fonction de scoring de confiance

État actuel : `compute_confidence()` non implémentée dans `WhisperModel`.

Contexte technique.

La HuggingFace pipeline("automatic-speech-recognition") en mode chunked (chunk_length_s=30, batch_size=8) ne retourne pas les scores par segment par défaut. Avec return_timestamps=True et output_scores=True dans la génération, des scores intermédiaires sont accessibles.

Proposition de scoring.

Soit $C = \{c_1, \dots, c_K\}$ les K chunks audio de durée Δt , et p_k la log-probabilité normalisée de séquence du chunk k (beam score, analogue à `TranslationModel`).

$$s_{\text{ASR}}(x, y) = (0.7 \cdot p + 0.3 \cdot \min_k p_k) \cdot \phi_{\text{SNR}}$$

où :

- $\bar{p} = \frac{1}{K} \sum_{k=1}^K \exp(\text{beam_score}_k) \in (0,1]$
- $\min_k p_k$ pénalise les chunks les plus incertains
- $\phi_{\text{SNR}} \in [0.5, 1]$: facteur optionnel basé sur le SNR estimé de l'audio (mesurable sans inférence)

Plage de valeurs. $s \in (0, 1]$

Interprétation des seuils.

Plage	Interprétation	Action recommandée
$s \geq 0.75$	Haute confiance	Exploitable
$0.45 \leq s < 0.75$	Confiance moyenne	Relecture recommandée
$s < 0.45$	Faible confiance	Relecture humaine obligatoire

3.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] Radford, A. et al. (2022). *Robust Speech Recognition via Large-Scale Weak Supervision*. arXiv:2212.04356. — Whisper, architecture et entraînement multilinguisme.

- [Ref 2] Peng, B. & Woodland, P. (2022). *Confidence Estimation for Attention-Based Encoder-Decoder ASR*. ICASSP. — Estimation de confiance pour systèmes seq2seq.
- [Ref 3] Kumar, A. et al. (2023). *Selective Prediction for Automatic Speech Recognition*. — Scoring de confiance ASR pour décision de rejet.
- [Ref 4] Nam, J. & Han, K.J. (2021). *Uncertainty Estimation for ASR: A Systematic Review*. — Survey des méthodes d'estimation d'incertitude ASR.

Alternatives considérées.

- Entropie des distributions de token : nécessite accès aux logits à chaque step — non exposé par la pipeline HF sans modification
- Détection de silence / SNR seul : mesure la qualité audio, pas la qualité de transcription — insuffisant seul

3.7 7. Validation empirique du score

Statut : protocole à mettre en œuvre.

Protocole.

- 1.Dataset audio annoté (transcriptions ground-truth)
- 2.Extraction des beam scores par chunk (modification de `WhisperModel.infer()`)
- 3.Calcul du WER réel par segment
- 4.Corrélation Spearman entre score proposé et $1 - \text{WER}_{\text{normalisé}}$

Corrélation score ↔ qualité.

Test statistique	Valeur	p-value	Interprétation
Spearman ρ	à mesurer	à mesurer	Attendu : $\rho > 0.5$
Pearson r	à mesurer	à mesurer	

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Audio studio FR propre	élevé	à mesurer	
Enregistrement téléphonique	moyen	à mesurer	
Audio avec bruit de fond intense	bas	à mesurer	
Locuteur accent fort / dialecte AR	bas	à mesurer	

3.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Parole simultanée multi-locuteurs (pas de diarisation dans l'implémentation actuelle)
- Audio très court (< 1 s) : le mécanisme de chunking produit des artefacts

Biais identifiés.

- WER plus élevé sur accents régionaux FR non représentés dans le pre-training
- Arabe dialectal (levantin, maghrébin) moins bien couvert que l'arabe MSA
- Biais de genre : voix féminines légèrement sous-représentées dans CommonVoice FR

Dérive prévisible.

- Si on passe à Faster-Whisper ou à une version quantifiée, les beam scores changent d'échelle

3.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score bas → relecture obligatoire. Seuils définis par type de risque d'erreur.
Art. 10 — Données et gouvernance	Dataset d'évaluation avec enregistrements anonymisés et consentement.
Art. 13 — Transparence	Score affiché par fichier audio sur le dashboard.
Art. 14 — Contrôle humain	Zone rouge : enquêteur doit valider manuellement la transcription avant usage.
Art. 15 — Exactitude, robustesse	Benchmark WER multilingue. Tests sur dégradations audio.

3.10 10. Monitoring en production

Métriques de suivi.

- Distribution des scores ASR par semaine
- Taux de segments en zone rouge
- RTF moyen (détection de ralentissements matériels)

Conditions de déclenchement d'une revue.

- Taux zone rouge > 20 % sur fenêtre 2 semaines
- Changement de modèle Whisper ou de mode d'inférence

Logs et traçabilité.

```
[CONFIDENCE]          model=DataPipelines.WhisperModel.WhisperModel
score=<float> metadata={...}
```

3.11 11. Annexes

- Code : [DataPipelines/WhisperModel.py](../DataPipelines/WhisperModel.py)

- Configuration : [config.ini](../config.ini) section [WHISPER]
- Modèle : openai/whisper-large-v3 (HuggingFace Hub)

Fiche composant — Embeddings (Modèle de représentation vectorielle)

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

4.1 1. Identification

Champ	Valeur
Nom du composant	Embeddings — Modèle de représentation vectorielle
Version / modèle retenu	BAAI/bge-m3
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon
Place dans le pipeline IDeXtend	DataPipelines/EmbeddingsModel.py → EmbeddingsHandler — utilisé à l'ingestion (indexation) et à la requête (recherche top-K)

4.2 2. Définition de la fonctionnalité

Rôle dans le système.

Le modèle d'embeddings encode les chunks de texte (et questions) en vecteurs denses de dimension fixe, permettant la recherche sémantique par similarité cosinus dans la base ArcadeDB. Il détermine les 25 meilleurs candidats transmis au reranker, puis au LLM. La qualité du retrieval conditionne directement la qualité des réponses aux enquêteurs.

Entrée.

- Format : `str` ou `list[str]` — chunks de texte (max ~1024 caractères, avec overlap de 128 chars)
- Source : texte extrait par OCR, ASR, ou ingestion directe de documents
- Volume typique : des centaines à des milliers de chunks par affaire

Sortie.

- Format : vecteur numpy `float16`, dimension fixe (BGE-M3 : 1024 dim)
- Consommateur en aval : base vectorielle ArcadeDB → `EmbeddingsHandler.find_most_similar()` → reranker

Criticité AI Act.

Un retrieval de mauvaise qualité (chunks non pertinents retournés parmi les top-25) conduit directement le LLM à répondre sur des bases incorrectes. Un score de confiance du retrieval bas doit signaler que la réponse peut être fondée sur des documents non pertinents.

4.3 3. Modèles évalués

Benchmark documenté dans `documentation_pierre/choosing_embeddings.md` et `documentation_pierre/embeddings_evaluation_results_*.xlsx`.

Modèle	Score moyen (pos. réponse)	Multilinguisme	VRAM	Retenu
paraphrase-multilingual-MiniLM-L12-v2	~31	oui	faible	non (baseline initiale)
BAAI/bge-m3	~4.7	oui (100+ langues)	~1.5 Go	oui
all-MiniLM-L6-v2	à reporter	anglais	faible	non
gte-Qwen2-7B-instruct	à reporter	oui	élevé	non
stella_en_1.5B_v5	à reporter	anglais	moyen	non

(Score = position moyenne de la réponse correcte dans le ranking — plus bas est mieux. 1 = toujours en 1ère position.)

Justification du modèle retenu.

BGE-M3 (BAAI) gagne sur tous les autres modèles testés avec un score moyen de 4.7 (vs 31 pour le modèle précédent), tout en supportant 100+ langues dont FR, EN, AR, DE. Sa taille (~560 Mo) est compatible avec le déploiement sur GPU partagé. Voir `documentation_pierre/choosing_embeddings.md` et `documentation_pierre/table.png`.

4.4 4. Protocole d'évaluation

Dataset d'évaluation.

- Protocole "needle in the haystack" : questions/réponses générées pour 4 langues (FR, EN, DE, ES)
- La réponse correcte est cachée dans un ensemble de chunks, le modèle doit la ranker en 1ère position
- Script disponible : `evaluate_embeddings.py`

Métriques de performance brute.

Description		
Rang moyen de la réponse correcte (plus bas = mieux)		
$\frac{1}{Q}$	Q	$\frac{1}{\sum_q \frac{1}{Q}}$

	Description		
	Proportion de questions où la bonne réponse est dans le top-K		
	Normalized Discounted Cumulative Gain		

Résultats du benchmark.

Modèle	Position moy.	MRR	Recall@25	VRAM (Go)
BGE-M3 (retenu)	4.7	à mesurer	à mesurer	~1.6
paraphrase-multilingual-MiniLM-L12-v2	31	à mesurer	à mesurer	<1

4.5 5. Fonction de scoring de confiance

État actuel : compute_confidence() non implémentée dans EmbeddingsModel.

Contexte.

Pour les embeddings, le score de confiance pertinent n'est pas la confiance du modèle d'encodage lui-même (les embeddings ne produisent pas de probabilité), mais la **qualité du retrieval** : dans quelle mesure les chunks retournés sont-ils pertinents à la question ?

Proposition de scoring (à l'heure de la requête).

Soit $S = \{s_1, \ldots, s_K\}$ les scores de similarité cosinus des K chunks retournés (top-K = 25 par défaut, seuil global `DEFAULT_THRESHOLD = 0.85`).

$$s_{\text{emb}}(q, \mathbf{C}) = (1)/(K) \sum_{k=1}^K s_k \cdot 1[s_k \geq \tau]$$

où $\tau = 0.85$ est le seuil de similarité minimum (`EmbeddingsHandler.DEFAULT_THRESHOLD`). En pratique, si tous les K chunks sont sous le seuil, $s_{\text{emb}} = 0$ (aucun document pertinent trouvé).

Variante plus informative — gap score :

$$s_{\text{gap}}(q) = s_1 - s_K$$

Un grand écart entre le meilleur et le pire chunk retenu indique que les meilleurs sont nettement plus pertinents — bon signal de confiance.

Plage de valeurs. $s_{\text{emb}} \in [0, 1]$, $s_{\text{gap}} \in [0, 1]$

Interprétation des seuils.

Plage s_{emb}	Interprétation	Action recommandée
$s \geq 0.87$	Retrieval cohérent	Réponse LLM probablement fondée

Plage s_{emb}	Interprétation	Action recommandée
$0.85 \leq s < 0.87$	Retrieval limité	Vérifier que le reranker affine bien
$s < 0.85$	Aucun chunk au-dessus du seuil	Signaler "aucun document pertinent trouvé"

4.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] Chen, J. et al. (2024). *BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. arXiv:2309.07597. — BGE-M3, architecture et performances multilingues.
- [Ref 2] Karpukhin, V. et al. (2020). *Dense Passage Retrieval for Open-Domain Question Answering*. arXiv:2004.04906. — DPR, fondement de la recherche par embedding dense.
- [Ref 3] Muennighoff, N. et al. (2023). *MTEB: Massive Text Embedding Benchmark*. arXiv:2210.07316. — Benchmark de référence pour comparer les modèles d'embedding.
- [Ref 4] Xiong, L. et al. (2021). *Approximate Nearest Neighbor Negative Contrastive Estimation for Dense Text Retrieval*. ICLR. — Effets de la qualité d'index sur le score de retrieval.

Hypothèses sous-jacentes.

La similarité cosinus entre embedding question et embedding chunk est un proxy valide de la pertinence sémantique pour les langues et domaines couverts par BGE-M3. Hypothèse à valider sur corpus judiciaire FR.

4.7 7. Validation empirique du score

Statut : benchmark existant (evaluate_embeddings.py) à compléter avec validation du score de confiance.

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Question en FR avec documents FR	élevé (> 0.87)	à mesurer	
Question sur sujet absent du corpus	bas (< 0.85)	à mesurer	
Question cross-linguale (FR question, AR docs)	moyen	à mesurer	
Question ambiguë / mal formulée	bas	à mesurer	

4.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Chunks très courts (< 50 tokens) : les embeddings peuvent être bruités
- Documents techniques (code, formules, balises XML) : la similarité sémantique est moins pertinente

Biais identifiés.

- BGE-M3 est entraîné principalement sur des textes web — domaine judiciaire peut diverger
- L'arabe dialectal (levantin, maghrébin) est moins bien représenté que l'arabe MSA dans l'entraînement

4.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score de retrieval faible → avertissement sur la qualité de la réponse LLM.
Art. 13 — Transparence	Score de similarité du meilleur chunk affiché avec chaque réponse.
Art. 14 — Contrôle humain	Si $\text{sim}(\text{emb}_{\text{query}}, \text{emb}_{\text{chunk}}) < 0.85$: message "aucun document suffisamment pertinent trouvé".
Art. 15 — Exactitude	Benchmark MRR/Recall@K sur dataset annoté.

4.10 10. Monitoring en production

Métriques de suivi.

- Distribution des scores de similarité top-1 par semaine
- Taux de requêtes sans chunk au-dessus du seuil (indicateur qualité corpus)

4.11 11. Annexes

- Code : [DataPipelines/EmbeddingsModel.py](../DataPipelines/EmbeddingsModel.py), [persistence/embeddingsHandler.py](../persistence/embeddingsHandler.py)
- Documentation benchmark existante : [documentation_pierre/choosing_embeddings.md](../documentation_pierre/choosing_embeddings.md)
- Script d'évaluation : [evaluate_embeddings.py](../evaluate_embeddings.py)
- Configuration : [config.ini](../config.ini) sections [SENTENCE.EMBEDDER], [THRESHOLD_EMBEDDER]

Fiche composant — Reranker (Reclassement sémantique)

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

5.1 1. Identification

Champ	Valeur
Nom du composant	Reranker — Reclassement sémantique des chunks candidats
Version / modèle retenu	BAAI/bge-reranker-v2-m3
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon
Place dans le pipeline IDeXtend	DataPipelines/Reranker.py → LargeLanguageHandler/reranker.py — consommé par LlmModelQuestion avant la génération de réponse

5.2 2. Définition de la fonctionnalité

Rôle dans le système.

Le reranker reçoit les 25 chunks candidats sélectionnés par les embeddings et les reclasse par pertinence à la question. Contrairement aux embeddings (encodage indépendant), le reranker est un **cross-encoder** qui traite le couple (question, chunk) ensemble. Il filtre ensuite les chunks non pertinents (score < 0.05) et applique une méthode de sélection (smart, kmeans, top, top_kmeans).

Entrée.

- Format : `tuple (question: str, candidates: list[str]) + paramètres rank_method, rank_top`
- Source : top-25 chunks retournés par `EmbeddingsHandler`
- Volume typique : 25 candidats par requête

Sortie.

- Format : `list[int]` — indices des chunks retenus dans l'ordre de pertinence décroissante
- Consommateur en aval : `LlmModelQuestion.LLM_answerQuestion()` — seuls ces chunks sont passés au LLM

Criticité AI Act.

Le reranker est le dernier filtre avant le LLM. Un reranker défaillant peut : (1) écarter des documents pertinents (faux négatifs), (2) transmettre des documents non pertinents au LLM (faux positifs), (3) biaiser la réponse finale.

5.3 3. Modèles évalués

Modèle	Version	Multilinguisme	Mode	Retenu
BAAI/bge-reranker-v2-m3	v2-m3	oui (100+ langues)	local	oui
BAAI/bge-reranker-base	base	anglais principalement	local	non
cross-encoder/ms-marco-MiniLM	MiniLM	anglais	local	non
cohere-rerank (API)	Rerank-3	oui	remote (API)	non (dépendance externe)

Évaluation disponible : `evaluate_rerankers.py` présent dans le projet.

Tests de régression : `Tests/test_reranker_regression.py` + `Tests/reranker_reference.json`.

5.4 4. Protocole d'évaluation

Dataset d'évaluation.

- Datasets multilingues disponibles : `dataset_crosslingual_easy.json`, `dataset_crosslingual_subtle.json`, `dataset_multilingual_easy.json`, `dataset_multilingual_subtle.json`
- Métriques : `nDCG@K`, `MRR`, `Recall@K`

Métriques de performance brute.

Métrique	Description
<code>nDCG@5</code>	Normalized Discounted Cumulative Gain — mesure la qualité du ranking
<code>MRR</code>	Mean Reciprocal Rank
<code>Précision@K</code>	Proportion de documents pertinents dans le top-K

Résultats du benchmark.

Modèle	<code>nDCG@5</code>	<code>MRR</code>	Latence (ms/requête)	VRAM
bge-reranker-v2-m3	à mesurer	à mesurer	à mesurer	~1.6 Go

5.5 5. Fonction de scoring de confiance

État actuel : `compute_confidence()` *implémentée* dans `DataPipelines/Reranker.py`.

Définition formelle.

Soit $\mathcal{S} = \{s_i : i \in \mathcal{I}_{\text{selected}}\}$ les scores bruts (pré-sigmoid) du cross-encoder pour les chunks retenus. Le cross-encoder BAAI/bge-reranker-v2-m3 produit un logit $l_i \in (-\infty, +\infty)$ par paire (question, chunk). La pertinence normalisée est :

$$s_i = \sigma(l_i) = (1)/(1 + e^{-l_i}) \in (0, 1)$$

Le score de confiance global est défini par :

$$s_{\text{reranker}}(q, \mathcal{C}) = 0.7 \cdot \bar{s} + 0.3 \cdot \min_{i \in \mathcal{I}} s_i$$

où $\bar{s} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} s_i$ est la moyenne des scores sigmoid des chunks retenus.

Cas particuliers :

- Aucun candidat retenu : $s = 0.0$, metadata reason: "no candidate retained"
- Candidat unique (fast path, pas de scoring) : $s = 0.5$, metadata reason: "unmeasured (single-candidate fast path)"

Plage de valeurs. $s \in [0, 1]$

Interprétation des seuils.

Plage	Interprétation	Action recommandée
$s \geq 0.70$	Bons candidats retenus, réponse LLM probablement pertinente	Exploitable
$0.40 \leq s < 0.70$	Candidats de pertinence moyenne	Vérification recommandée
$s < 0.40$	Peu de candidats pertinents	Avertissement affiché, relecture recommandée

Metadata loguée :

```
{
  "num_selected": 5,
  "mean_score": 0.724,
  "min_score": 0.512,
  "max_score": 0.891,
  "per_index_scores": {"0": 0.891, "3": 0.724, "7": 0.693, ...}
}
```

5.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] Chen, J. et al. (2024). *BGE M3-Embedding*. arXiv:2309.07597. — BGE-reranker-v2-m3 : architecture cross-encoder multilingue.
- [Ref 2] Nogueira, R. & Cho, K. (2019). *Passage Re-ranking with BERT*. arXiv:1901.04085. — Fondement du cross-encoder comme reranker.
- [Ref 3] Pradeep, R. et al. (2023). *RankLLaMA: Neural Ranking with Large Language Models*. — Comparaison cross-encoder vs LLM reranking.
- [Ref 4] Glass, M. et al. (2022). *Re2G: Retrieve, Rerank, Generate*. — Pipeline RAG avec reranker, analyse du gain de qualité.

Justification du composite 0.7/0.3.

La pondération `0.7 × mean + 0.3 × min` est inspirée de la même formule dans `TranslationModel` : le `mean` capture la pertinence globale de l'ensemble retenu, le `min` pénalise les cas où un chunk faible est quand même passé au LLM. Le `min` seul serait trop sévère (un bon ensemble pénalisé par un borderline) ; le `mean` seul ignore les cas de pollution.

Hypothèses sous-jacentes.

- La sigmoid du logit cross-encoder est un proxy calibré de la probabilité de pertinence binaire (pertinent / non pertinent)
- La méthode de sélection `smart` (detection kmeans vs top selon distribution des scores) est adaptée à la plupart des cas

5.7 7. Validation empirique du score

Protocole.

Dataset annoté de pertinence (paires question/chunk labellisées 0 ou 1) → corrélation entre score reranker et labels.

Corrélation score ↔ qualité.

Test statistique	Valeur	p-value	Interprétation
Spearman ρ (score vs pertinence)	à mesurer	à mesurer	Attendu : ρ > 0.6
AUC-ROC (classification pertinent/non-pertinent)	à mesurer	à mesurer	Attendu : > 0.80

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Question avec réponse directe dans le corpus	élevé (> 0.70)	à mesurer	
Question hors domaine (aucune réponse pertinente)	bas (< 0.40)	à mesurer	
Requête cross-linguale FR→AR	moyen	à mesurer	

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Jeu subtil (dataset_*_subtle.json)	plus bas	à mesurer	

5.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Méthode smart avec distributions de scores très étalées : la détection kmeans peut classer arbitrairement
- Single-candidate fast path : score fixé à 0.5 par convention, non informatif

Biais identifiés.

- Légèrement biaisé vers les textes anglais malgré le multilingue de bge-v2-m3
- Textes longs (>512 tokens) tronqués avant reranking — biais de longueur

Dérive prévisible.

- Si la distribution des questions change (nouveau type d'enquête), les seuils de `minimum_acceptable_score = 0.05` peuvent nécessiter un recalibrage

5.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score bas → avertissement sur la pertinence des sources LLM.
Art. 13 — Transparence	<code>per_index_scores</code> dans les métadonnées : traçabilité de chaque chunk sélectionné.
Art. 14 — Contrôle humain	Score global affiché par réponse. Enquêteur peut consulter les sources brutes.
Art. 15 — Exactitude	Tests de régression automatisés (<code>test_reranker_regression.py</code>).

5.10 10. Monitoring en production

Métriques de suivi.

- Distribution des scores moyen par requête par semaine
- Taux de requêtes avec 0 candidat retenu (`num_selected = 0`)
- Latence du reranker (VRAM et CPU mode comparés)

Conditions de déclenchement d'une revue.

- Taux `num_selected = 0 > 10 %` sur 1 semaine
- Changement de modèle reranker ou de méthode de sélection

5.11 11. Annexes

- Code : [DataPipelines/Reranker.py](../DataPipelines/Reranker.py),
[LargeLanguageHandler/reranker.py](../LargeLanguageHandler/reranker.py)
- Tests de régression : [Tests/test_reranker_regression.py](../Tests/test_reranker_regression.py)
- Référence de régression : [Tests/reranker_reference.json](../Tests/reranker_reference.json)
- Script d'évaluation : [evaluate_rerankers.py](../evaluate_rerankers.py)
- Datasets : `dataset_crosslingual_*.json`, `dataset_multilingual_*.json`
- Configuration : [config.ini](../config.ini) section [reranker]

Fiche composant — LLM (Grand Modèle de Langage) — Qwen3

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

Point critique : les log-probs de séquence seuls sont insuffisants pour ce composant.

6.1 1. Identification

Champ	Valeur
Nom du composant	LLM — Grand Modèle de Langage (inférence et Q&A)
Version / modèle retenu	Qwen3-4B-Instruct-ctx-8k-30-user (via vLLM / llama.cpp)
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon — approche de scoring composite à définir
Place dans le pipeline IDeXtend	DataPipelines/LlmModel.py → LlmModelQuestion (Q&A), LlmModelIngestion (ingestion)

6.2 2. Définition de la fonctionnalité

Rôle dans le système.

Le LLM est le composant de génération finale : il produit les réponses aux questions des enquêteurs, les résumés de documents, les titres, et les relations entre entités. Il reçoit les chunks filtrés par le reranker et génère une réponse textuelle en langage naturel.

Entrée.

- Format : prompt structuré (instruction + contexte chunks + question) — format `LLM_prompt`
- Source : chunks retenus par le reranker (`LlmModelQuestion`), ou document complet (`LlmModelIngestion`)
- Volume typique : 1 000 à 8 000 tokens par appel (fenêtre contexte = 8k)

Sortie.

- Format : `str` ou `dict` (JSON structuré pour extraction d'entités)
- Consommateur en aval : frontend `Vue.js` (réponse enquêteur), `CypherHandler` (graphe d'entités)

Criticité AI Act.

Le LLM est la brique la plus visible par les enquêteurs. Une réponse erronée avec haute confiance affichée est le scénario d'échec le plus grave. Le score de confiance LLM doit détecter : (1) les hallucinations (affirmations sans fondement dans les chunks fournis), (2) les réponses vagues ou évasives, (3) les réponses fondées sur un contexte insuffisant.

6.3 3. Modèles évalués

Modèle	Version	Contexte	Nb users (GPU 7G)	Retenu
Qwen3-4B	4B Q8, ctx-8k	8k	30	oui (actuel)
Qwen2.5-7B	7B Q8, ctx-8k	8k	15–30	non (trop lent à débit élevé)
Qwen3-14B	14B, ctx-8k/50k	8k–50k	2–15	non (VRAM élevée)
Qwen3-30B-A3B (MoE)	30B MoE, vLLM	variable	à évaluer	à évaluer
c4ai-command-r-v01	7B Q4/Q8, ctx-30k	30k	6–18	non (remplacé)

Critères de présélection.

- Instruction following FR/EN/AR robuste
- Contexte $\geq 8k$ tokens (pour multi-documents)
- Débit compatible multi-utilisateurs (Gendarmerie : ~ 30 utilisateurs concurrents)
- Génération JSON structuré pour extraction d'entités

6.4 4. Protocole d'évaluation

Dataset d'évaluation.

- Q&A : dataset de questions avec réponses attendues extraites de documents réels anonymisés
- Métriques : ROUGE-L, BERTScore, F1-answer (pour extraction d'entités), hallucination rate

Métriques de performance brute.

Métrique	Description
ROUGE-L	Overlap de n-grammes avec réponse de référence
BERTScore	Similarité sémantique via BERT entre réponse générée et référence
Hallucination rate	Proportion d'affirmations non fondées dans les chunks fournis
Exact Match (JSON)	Pour les sorties structurées (extraction d'entités)

Résultats du benchmark.

Modèle	ROUGE-L	BERTScore	Hallucination rate	Latence (tok/s)
Qwen3-4B (actuel)	à mesurer	à mesurer	à mesurer	à mesurer
Qwen2.5-7B	à mesurer	à mesurer	à mesurer	à mesurer

6.5 5. Fonction de scoring de confiance

État actuel : `compute_confidence()` *non implémentée* dans `LlmModel`.

Approche à définir : *log-probs seuls insuffisants* (voir section 6).

6.5.1 5.1 Pourquoi les log-probs séquentiels sont insuffisants

Pour un modèle de génération autorégressif, la probabilité de séquence $P(\hat{y} \mid x) = \prod_t P(y_t \mid y_{<t}, x)$ est :

- **mal calibrée** pour les LLMs instruits par RLHF/DPO (les scores absolus sont peu interprétables)
- **biaisée par la longueur** : les réponses courtes ont des log-probs plus élevés mécaniquement
- **non discriminante des hallucinations** : un modèle peut être très confiant en générant une information fausse

6.5.2 5.2 Approche composite proposée (à valider)

Nous proposons un score composite combinant deux signaux orthogonaux :

Signal 1 — Ancrage contextuel (grounding score)

Mesure dans quelle mesure la réponse est fondée sur les chunks fournis. Deux variantes :

Variante A (lexicale) :

$$s_{\text{ground}}^A = |\text{tokens}(y_{\blacksquare}) \cap \text{tokens}(C)| / |\text{tokens}(y_{\blacksquare})|$$

où C est la concaténation des chunks fournis au LLM.

Variante B (sémantique, plus robuste) :

$$s_{\text{ground}}^B = (\text{emb}(y_{\blacksquare}), \text{emb}(C_{\text{top1}}))$$

où C_{top1} est le chunk reranker le mieux scoré — réutilise l'embedder déjà en mémoire.

Signal 2 — Confiance verbalisée (self-assessment)

Ajouter en fin de prompt système : *"After your answer, rate your confidence on a scale from 0 to 100. Format: CONFIDENCE: <integer>"*

$$s_{\text{verb}} = c_{\text{verb100}} \cdot \delta_{\text{parse}} \in [0, 1]$$

où $\delta_{\text{parse}} = 1$ si le format est respecté, 0.3 sinon (pénalité pour non-compliance).

Score composite final :

$$[s_{\text{LLM}}](x, y_{\blacksquare}) = \alpha \cdot s_{\text{ground}} + (1-\alpha) \cdot s_{\text{verb}}$$

avec $\alpha = 0.6$ (ancrage prévaut sur auto-évaluation — à calibrer empiriquement).

Plage de valeurs. $s \in [0, 1]$

Interprétation des seuils.

Plage	Interprétation	Action recommandée
$s \geq 0.75$	Réponse bien ancrée et modèle confiant	Exploitable
$0.50 \leq s < 0.75$	Ancrage partiel ou confiance modérée	Relecture recommandée
$s < 0.50$	Réponse potentiellement non fondée	Relecture humaine obligatoire, flag "hallucination possible"

6.5.3 5.3 Alternative : Semantic Entropy (pour étude future)

La semantic entropy (Kuhn et al., 2023) mesure l'incertitude sémantique par K générations :

$$s_{SE}(x) = -\sum_{c \in C} p(c|x) \log p(c|x)$$

où $\mathcal{C}$ sont les classes sémantiques des K sorties. Score bas = forte cohérence = haute confiance.

Coût : K inférences ($K=5$ minimum) $\rightarrow 5 \times$ la latence. Non retenu pour la production, à évaluer en contexte de faible trafic.

6.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] Kuhn, L. et al. (2023). *Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation*. ICLR. — Fondement de la semantic entropy, référence principale pour scoring NLG.
- [Ref 2] Kadavath, S. et al. (2022). *Language Models (Mostly) Know What They Know*. arXiv:2207.05221. — $P(\text{True})$ / verbalized confidence : les LLMs sont partiellement calibrés sur leur auto-évaluation.
- [Ref 3] Guo, C. et al. (2017). *On Calibration of Modern Neural Networks*. ICML. — Mauvaise calibration des réseaux profonds ; Temperature Scaling comme correctif.
- [Ref 4] Manakul, P. et al. (2023). *SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models*. arXiv:2303.08896. — Détection d'hallucinations par consistency multi-sampling.
- [Ref 5] Min, S. et al. (2023). *FActScoring: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation*. — Évaluation factuelle fine-grained.
- [Ref 6] Mündler, N. et al. (2024). *Self-Contradictory Hallucinations of Large Language Models: Evaluation, Detection and Mitigation*. — Incohérence interne comme signal d'hallucination.

Alternatives considérées et rejetées.

- Log-probs token uniquement** : non calibrés post-RLHF, trop biaisés par la longueur. (Voir section 5.1)
- Ensemble disagreement** : nécessite plusieurs modèles LLM — trop coûteux en VRAM.
- NLI-based entailment** : vérifier si $\hat{y}$ est impliqué par C via un modèle NLI (ex. DeBERTa-NLI). Intéressant mais ajoute un modèle supplémentaire.

6.7 7. Validation empirique du score

Statut : protocole à définir — expériences à conduire après implémentation du scoring.

Protocole.

- 1.Constituer un dataset de 100 paires (question, chunks, réponse générée, étiquette hallucination)
- 2.Annotation : deux annotateurs vérifient si la réponse est fondée sur les chunks fournis
- 3.Calculer le score composite pour chaque réponse
- 4.Évaluer la corrélation score $\leftrightarrow$ label hallucination (AUC-ROC)

Corrélation score $\leftrightarrow$ qualité.

Test statistique	Valeur	p-value	Interprétation
AUC-ROC (hallucination vs non-hallucination)	à mesurer	—	Attendu : > 0.70
Spearman ρ (score vs BERTScore)	à mesurer	à mesurer	

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Question avec réponse explicite dans les chunks	élevé (> 0.75)	à mesurer	
Question sans réponse dans les chunks	bas (< 0.50)	à mesurer	
Question hors domaine (aucun document pertinent)	bas	à mesurer	
Prompt adversarial (injection de contexte trompeur)	bas	à mesurer	

6.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Le grounding lexical est faible pour les paraphrases (la réponse est correcte mais reformulée)
- La confiance verbalisée peut être trop conservatrice ou trop optimiste selon le fine-tuning Qwen3

Biais identifiés.

- Le modèle peut sur-confier quand il reproduit des formulations proches du prompt (mémorisation)
- Les réponses très courtes ont un grounding score élevé mécaniquement

Dérive prévisible.

- Changement de modèle LLM (version, quantization) : recalibrer α et les seuils
- Changement du format de prompt : vérifier la compliance du token CONFIDENCE

6.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score composite détecte les hallucinations et le manque d'ancrage.
Art. 13 — Transparence	Score affiché par réponse. Sources (chunks) listées.
Art. 14 — Contrôle humain	Zone rouge → flag "hallucination possible" visible enquêteur. Les sources sont toujours consultables.
Art. 15 — Exactitude	Benchmark ROUGE/BERTScore/Hallucination rate. Monitoring de la distribution des scores.

6.10 10. Monitoring en production

Métriques de suivi.

- Distribution du score composite par semaine
- Taux de réponses en zone rouge (score < 0.50) — indicateur de qualité du retrieval
- Taux de non-compliance du token CONFIDENCE (indicateur de dérive prompt)

Conditions de déclenchement d'une revue.

- Taux zone rouge > 15 % sur 1 semaine
- Taux non-compliance CONFIDENCE > 5 %
- Changement de modèle LLM ou de prompt template

6.11 11. Annexes

- Code : [DataPipelines/LlmModel.py](../DataPipelines/LlmModel.py), [LargeLanguageHandler/rag.py](../LargeLanguageHandler/rag.py)
- Configurations LLM : `llm_configs/Qwen3-4B-Instruct-ctx-8k-30-user.yaml`
- Config active : [config.ini](../config.ini) sections [LLM.ingestion], [LLM.questions]

Fiche composant — Traduction automatique — NLLB-600M

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

7.1 1. Identification

Champ	Valeur
Nom du composant	Traduction automatique
Version / modèle retenu	facebook/nllb-200-distilled-600M (NLLB)
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon
Place dans le pipeline IDeXtend	DataPipelines/TranslationModel.py — déclenché lors de l'ingestion si la langue détectée $\neq$ fra_Latn

7.2 2. Définition de la fonctionnalité

Rôle dans le système.

Le composant de traduction normalise tous les documents vers le français avant l'ingestion dans la base vectorielle. Cette normalisation est nécessaire car les embeddings et le LLM sont optimisés pour le français. La traduction est appliquée chunk par chunk avec un beam search sur 5 candidats.

Entrée.

- Format : texte `str`, langue source BCP-47 (ex. `eng_Latn`, `ara_Arab`, `arb_Latn`)
- Source : texte extrait par OCR, ASR, ou ingestion directe, dont la langue diffère de `fra_Latn`
- Volume typique : quelques phrases à plusieurs pages par document

Sortie.

- Format : texte traduit en `fra_Latn`
- Consommateur en aval : `EmbeddingsModel` (chunking + vectorisation du texte traduit)

Criticité AI Act.

Une mauvaise traduction peut : (1) altérer le sens d'un aveu ou d'une déclaration, (2) introduire des termes inexacts qui faussent la recherche par mots-clés, (3) perdre des nuances culturelles/dialectales importantes.

7.3 3. Modèles évalués

Benchmark disponible dans `scoring_rayan/_archive/` :

- Fichiers : `benchmark_nllb_vs_qwen.csv`,
`benchmark_nllb_vs_qwen_summary.csv`, `benchmark_traduction_memo.md`
- Dataset : FLORES+ devtest, 200 phrases, 8 paires de langues (FR↔EN, FR↔AR MSA, FR↔AR Levantin)

Modèle	FR→EN	EN→FR	FR→AR	AR→FR	Vitesse (ms/phrased)	Retenu
NLLB-600M	41.0	46.3	13.9	29.7	~130–180	oui
Qwen3.5-4B	41.2	44.7	14.5	29.3	~660–900	non
TGemma-4B	37.9	40.4	14.5	26.4	~620–940	non
Qwen-2B	37.8	38.9	10.0	20.5	~490–670	non
Qwen-0.8B	33.1	31.6	4.7	12.8	~470–760	non

(Métriques : BLEU. Gagnant en gras pour chaque paire.)

Justification du modèle retenu.

NLLB-600M gagne sur 5-6/8 directions et est 4-5× plus rapide que les LLM testés. Son rapport qualité/vitesse/taille est optimal pour une utilisation intensive multi-utilisateurs. Voir `scoring_rayan/_archive/benchmark_traduction_memo.md` pour les détails.

Modèles non encore benchmarkés : Qwen3.5-9B, Qwen3.5-27B-Q4, Aya-23-8B.

7.4 4. Protocole d'évaluation

Dataset d'évaluation.

- FLORES+ devtest : 200 phrases par paire, 8 paires de langues
- Script : `scoring_rayan/_archive/bench_nllb_vs_qwen.py`
- Métriques : BLEU, chrF++, vitesse (ms/phrased)

Résultats du benchmark.

Voir `tableau` `section` `3.` `CSV` `détaillé` : `scoring_rayan/_archive/benchmark_nllb_vs_qwen.csv`.

7.5 5. Fonction de scoring de confiance

État actuel : `compute_confidence()` *implémentée dans* `DataPipelines/TranslationModel.py`.

Définition formelle.

NLLB utilise un beam search de $B=5$ faisceaux. Pour chaque chunk $k \in \{1, \dots, K\}$:

- seq_score_k = log-probabilité normalisée de la séquence best-beam : $\ell_k \in (-\infty, 0]$
- Probabilité de beam : $p_k = \exp(\ell_k) \in (0, 1]$
- Ratio de longueur : $r_k = \frac{\text{output_len}_k}{\text{input_len}_k}$ — détecte troncature ($r < 0.3$) ou emballement ($r > 4$)

Pénalité d'aberration :

$$\phi = 1 - \mathbb{I}_{k : r_k < 0.3 \text{ ou } r_k > 4} \cdot K \cdot 0.5$$

Score de confiance composite :

$$s_{\text{trad}}(x, y) = (0.7 \cdot p + 0.3 \cdot \min_k p_k) \cdot \phi$$

où $\bar{p} = \frac{1}{K} \sum_k p_k$ est la probabilité moyenne sur les chunks.

Plage de valeurs. $s \in (0, 1]$

Interprétation des seuils.

Plage	Interprétation	Action recommandée
$s \geq 0.70$	Traduction fiable	Exploitable
$0.40 \leq s < 0.70$	Traduction incertaine	Vérification recommandée
$s < 0.40$	Traduction très incertaine	Relecture humaine, notamment pour langues peu dotées

Metadata loguée :

```
{
  "num_chunks": 3,
  "src_lang": "ara_Arab",
  "tgt_lang": "fra_Latn",
  "mean_beam_prob": 0.512,
  "min_beam_prob": 0.234,
  "outlier_chunks": 0
}
```

7.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] NLLB Team (2022). *No Language Left Behind: Scaling Human-Centered Machine Translation*. arXiv:2207.04672. — NLLB-200, architecture et performances 200 langues.
- [Ref 2] Wiseman, S. & Rush, A. (2016). *Sequence-to-Sequence Learning as Beam-Search Optimization*. — Beam search NMT et interprétation des scores.
- [Ref 3] Ott, M. et al. (2018). *Analyzing Uncertainty in Neural Machine Translation*. — Calibration des scores beam en NMT.

- [Ref 4] Blatz, J. et al. (2004). *Confidence Estimation for Machine Translation*. COLING. — Fondements de l'estimation de confiance en MT.
- [Ref 5] Fomicheva, M. et al. (2020). *Unsupervised Quality Estimation for Neural Machine Translation*. TACL. — QE sans supervision par scores internes.

Justification du composite 0.7/0.3.

Le mean capture la qualité globale de la traduction (tous les chunks bien traduits = score élevé). Le min pénalise les cas où un chunk problématique (ex. terme en arabe dialectal sans équivalent) tire vers le bas sans faire baisser la moyenne de façon visible.

Hypothèses sous-jacentes.

- Les beam scores de NLLB sont mieux calibrés que ceux des LLMs instruits (pas de RLHF sur NLLB)
- La normalisation par longueur de séquence atténue le biais de longueur

7.7 7. Validation empirique du score

Protocole.

Dataset FLORES+ avec BLEU de référence → corrélation entre score de confiance et BLEU par phrase.

Corrélation score ↔ qualité (à mesurer sur FLORES+).

Test statistique	Valeur	p-value	Interprétation
Spearman ρ (score vs BLEU)	à mesurer	à mesurer	Attendu : ρ > 0.40
Pearson r	à mesurer	à mesurer	

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Texte FR standard vers EN	élevé (> 0.70)	à mesurer	
Texte AR MSA vers FR	moyen (0.40–0.70)	à mesurer	
Texte AR Levantin (dialectal) vers FR	bas (< 0.50)	à mesurer	
Texte très court (< 5 mots)	variable	à mesurer	
Termes propres (noms, adresses)	bas (score attendu bas sur entités)	à mesurer	

7.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Langues peu dotées (dialectes arabes, langues rares) : beam scores élevés mais traduction de mauvaise qualité
- Textes avec entités nommées (noms propres) : NLLB translittère ou invente des traductions

Biais identifiés.

- Performance significativement plus faible sur arabe dialectal (levantin, maghrébin) vs MSA
- Les textes très longs (> 450 tokens par chunk) sont tronqués : biais de longueur

Dérive prévisible.

- Si NLLB est remplacé par un LLM de traduction, toute la fonction de scoring doit être revue
- Recalibrer si on ajoute une nouvelle langue cible (ex. ES, DE)

7.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score bas sur langues peu dotées → avertissement "traduction incertaine".
Art. 13 — Transparence	Langue source, langue cible, et score affichés par document traduit.
Art. 14 — Contrôle humain	Zone rouge → enquêteur averti que la traduction est à vérifier.
Art. 15 — Exactitude	Benchmark BLEU/chrF++ sur FLORES+. Score corrélé à la qualité empirique.

7.10 10. Monitoring en production

Métriques de suivi.

- Distribution des scores par paire de langues
- Taux de chunks outlier (`outlier_chunks > 0`)

7.11 11. Annexes

- Code : `[DataPipelines/TranslationModel.py](../../DataPipelines/TranslationModel.py)`
- Benchmark : `[scoring_rayan/_archive/benchmark_traduction_memo.md](../_archive/benchmark_traduction_memo.md)`
- CSV benchmark : `scoring_rayan/_archive/benchmark_nllb_vs_qwen.csv`
- Script benchmark : `scoring_rayan/_archive/bench_nllb_vs_qwen.py`
- Configuration : `[config.ini](../../config.ini)` section `[LLM] translation_model`

Fiche composant — Détection automatique de langue

Documentation du scoring de confiance — conformité AI Act (Art. 9, 13, 15).

8.1 1. Identification

Champ	Valeur
Nom du composant	Détection automatique de langue
Version / modèle retenu	facebook/fasttext-language-identification (FastText LID)
Date de rédaction	2026-05-11
Auteur(s)	Rayan Leveque
Statut	brouillon
Place dans le pipeline IDeXtend	DataPipelines/LanguageDetection.py — premier composant appelé lors de l'ingestion et après OCR/ASR

8.2 2. Définition de la fonctionnalité

Rôle dans le système.

La détection de langue détermine la langue du texte extrait afin de décider si une traduction vers `fra_Latn` est nécessaire. Elle conditionne directement : (1) l'activation du composant de traduction, (2) le paramétrage du tokenizer NLLB (langue source), (3) potentiellement la sélection du modèle OCR optimal pour la langue détectée.

Entrée.

- Format : `str` — les 700 premiers caractères + caractères 1500–2500 du texte (fenêtre tronquée, optimisée pour FastText)
- Source : texte brut extrait par OCR, ASR, ou ingestion directe
- Volume typique : quelques centaines à quelques milliers de caractères

Sortie.

- Format : `tuple (lang_code: str, score: float)` — ex. `("fra_Latn", 0.98)`
- Code langue : format BCP-47 FLORES-200 (ex. `fra_Latn`, `eng_Latn`, `ara_Arab`, `arb_Latn`)
- Consommateur en aval : `DataIngestion` → routing vers `TranslationModel` si `lang` $\neq$ `fra_Latn`

Criticité AI Act.

Une détection de langue erronée peut conduire à : (1) ne pas traduire un document en langue étrangère (données non indexées correctement), (2) déclencher une traduction inutile d'un document déjà en français (coût + dégradation potentielle).

8.3 3. Modèles évalués

Modèle	Nb langues supportées	Taille	Vitesse	Retenu
facebook/fasttext-language-identification	217	~1 Mo	< 1 ms	oui
langdetect (Python)	55	< 1 Mo	quelques ms	non évalué
lingua-py	75	> 100 Mo	< 1 ms	non évalué
CLD3 (Google Compact Language Detector)	107	< 1 Mo	< 1 ms	non évalué

Critères de présélection.

- Support FR, EN, AR MSA, AR Levantin (arb_Latn), DE — langues cibles Gendarmerie
- Vitesse < 10 ms (ne doit pas ralentir le pipeline)
- Déployable on-premise sans dépendance réseau

8.4 4. Protocole d'évaluation

Dataset d'évaluation.

- Public : FLORES+ identification set, passages Wikipedia multilingues
- Interne : échantillon de documents opérationnels anonymisés

Métriques de performance brute.

Métrique	Description
Accuracy@1	Taux de la langue correcte en top-1
Accuracy@2	Taux de la langue correcte dans les top-2 prédictions
Macro-F1	F1 moyen par langue (équité entre langues)

Résultats du benchmark.

Modèle	Accuracy@1 (FR/EN/AR)	Latence (ms)	Taille
FastText LID	à mesurer	< 1	~1 Mo

8.5 5. Fonction de scoring de confiance

État actuel : `compute_confidence()` *implémentée* dans `DataPipelines/LanguageDetection.py`.

Définition formelle.

FastText produit pour chaque texte un vecteur de probabilités sur les 217 langues (softmax sur les labels). Le score de confiance est directement la probabilité softmax de la langue la plus probable :

$$s_{\text{LID}}(x) = P(\hat{l} \mid x) = \max_{l \in L} P(l \mid x) \in (0, 1]$$

où $\hat{l} = \arg\max_{l \in L} P(l \mid x)$ est la langue prédite.

L'implémentation utilise `detect(text, k=2)` — top-2 prédictions sont stockées dans les métadonnées.

Plage de valeurs. $s \in (0, 1]$ — en pratique $s > 0.3$ pour la plupart des textes.

Interprétation des seuils.

Plage	Interprétation	Action recommandée
$s \geq 0.90$	Langue détectée avec très haute confiance	Décision automatique de traduction fiable
$0.60 \leq s < 0.90$	Langue probable mais incertitude non négligeable	Logging, vérifier si le texte est vraiment monolingue
$s < 0.60$	Détection ambiguë	Ne pas déclencher de traduction automatique ; signaler texte multilingue possible

Metadata loguée :

```
{
  "detected_lang": "fra_Latn",
  "top_k": [
    {"lang": "fra_Latn", "score": 0.981},
    {"lang": "eng_Latn", "score": 0.012}
  ]
}
```

8.6 6. Justification scientifique de la fonction

État de l'art.

- [Ref 1] Joulin, A. et al. (2017). *Bag of Tricks for Efficient Text Classification*. EACL. — Fondement de FastText, probabilités softmax calibrées sur grande échelle.
- [Ref 2] Joulin, A. et al. (2016). *FastText.zip: Compressing text classification models*. arXiv:1612.03651. — Modèle compressé pour déploiement on-premise.
- [Ref 3] NLLB Team (2022). *No Language Left Behind*. arXiv:2207.04672. — Identification de langue pour 217 langues, dont dialectes arabes.
- [Ref 4] Caswell, I. et al. (2020). *Language ID in the Wild: Unexpected Challenges on the Path to a Thousand-Language Web Text Dataset*. COLING. — Cas difficiles de détection de langue (code-switching, texte court, dialectes).

Hypothèses sous-jacentes.

- Le score softmax FastText est bien calibré pour les textes de plus de 100 caractères
- Les textes très courts (< 20 caractères) ont des scores moins fiables — à signaler

8.7 7. Validation empirique du score

Protocole.

Dataset multilingue annoté → corrélation entre score FastText et taux d'erreur d'identification.

Corrélation score ↔ qualité.

Test statistique	Valeur	p-value	Interprétation
Spearman ρ (score vs accuracy@1)	à mesurer	à mesurer	Attendu : $\rho > 0.60$
AUC-ROC (correct/incorrect)	à mesurer	—	Attendu : > 0.80
ECE	à mesurer	—	Calibration softmax

Stress tests.

Cas	Score moyen attendu	Score moyen observé	Conforme ?
Document FR pur, > 200 caractères	très élevé (> 0.95)	à mesurer	
Texte bilingue FR/AR mélangé	bas (< 0.60)	à mesurer	
Texte court < 20 caractères	variable / bas	à mesurer	
Arabe dialectal levantin (arb_Latn)	moyen	à mesurer	
Translittération arabe en latin	bas	à mesurer	

8.8 8. Limites et conditions d'usage

Cas où le score est non fiable.

- Textes très courts (< 20 caractères) : FastText a peu de signal
- Code-switching (mélange de langues dans une même phrase) : la langue majoritaire est détectée, l'autre ignorée
- Textes avec de nombreuses entités nommées (noms propres, codes) : biais vers la langue du contexte

Biais identifiés.

- L'arabe dialectal (levantin, maghrébin) peut être confondu avec l'arabe MSA, ou classé dans une catégorie sous-représentée
- Textes en alphabet latin non-latin (translittération arabe) : confusion avec FR/EN/DE

Dérive prévisible.

- Si de nouvelles langues sont ajoutées au corpus (ex. turc, persan), recalibrer les seuils
- Le modèle FastText ne se met pas à jour — stable mais non adaptatif

8.9 9. Conformité AI Act

Article / exigence	Comment ce composant y répond
Art. 9 — Gestion des risques	Score bas → ne pas déclencher de traduction automatique sans vérification.
Art. 13 — Transparence	Langue détectée + score + top-2 alternatives loguées par document.
Art. 14 — Contrôle humain	Zone ambiguë ($s < 0.60$) : signaler à l'enquêteur que la langue est incertaine.
Art. 15 — Exactitude	Benchmark Accuracy@1 sur FLORES+ et corpus opérationnel.

8.10 10. Monitoring en production

Métriques de suivi.

- Distribution des scores de détection par semaine
- Fréquence des langues détectées (distribution multilingue du corpus ingéré)
- Taux de détections ambiguës ($s < 0.60$)

Conditions de déclenchement d'une revue.

- Taux de détections ambiguës $> 10\%$ sur 1 semaine
- Apparition d'une nouvelle langue non supportée par FastText

8.11 11. Annexes

- Code : [DataPipelines/LanguageDetection.py](../DataPipelines/LanguageDetection.py)
- Configuration : [config.ini](../config.ini) [LLM] language_detection = facebook/fasttext-language-identification
- Codes langue : [utils/lang_to_BCP-47.json](../utils/lang_to_BCP-47.json)